

X-Ray

X-Ray

Ideja vodilja za učenje, istraživanje i izgradnju sistema

Flavio · 2026 · Živi dokument · v3b

Prolog: Dvije knjige

Početkom sedamdesetih godina prošlog vijeka pročitao sam knjigu *Dole škole (Deschooling Society)* Ivana Ilića — austrijskog filozofa i društvenog kritičara koji je cijeli život pisao o onome što institucije rade ljudima dok se tvare da im pomažu.

Ilić nije pisao o lošim školama. Pisao je o samoj strukturi institucionalnog učenja i zašto ona sistemski sprečava upravo ono što tvrdi da proizvodi. Škole — kao institucije — ne uče ljude da misle. Uče ih da se pokoravaju. Zamjenjuju iskrenu želju za razumijevanjem certifikatima, ocjenama i iluzijom napretka.

Knjiga me uznemiravala. Ne zato što sam je odbio — nego zato što sam je prepoznao.

Početkom devedesetih pročitao sam *Flatland: A Romance of Many Dimensions* Edwina A. Abbotta, engleskog učitelja koji je 1884. napisao priču o dvodimenzionalnom svijetu. Stanovnici Flatlanda ne mogu zamisliti treću dimenziju — ne zbog nedostatka inteligencije, već zato što je njihov cjelokupni perceptivni aparat izgrađen za stvarnost koja je jednostavno ne sadrži. Zatvor nije od rešetaka. Zatvor je od referentnog okvira.

I tu knjigu sam prepoznao.

Te dvije knjige oblikovale su ne samo moj pogled na svijet, nego moj cjelokupni profesionalni i intelektualni razvoj. Ilić mi je pokazao institucionalni zatvor. Abbott perceptivni. Zajedno su opisali dvije dimenzije iste zatvorenosti — i obje sam vidio u sebi.

Očekivao sam da ću u nekom trenutku doći do odgovora. Nisam. Ne razumijem potpuno svijet oko sebe. Nisam pronašao potpun odgovor na pitanje zašto i kako radim ono što radim.

Naglašavam: do sada. Idem dalje.

Postoji vrsta znanja koja zadovoljava opisom površine. Možeš znati da jato ptica leti, a da nikad ne postaviš pitanje tko ga vodi. Možeš koristiti algoritam, a da nikad ne pogledaš što se zapravo dešava unutra. Možeš upravljati sistemom koji radi — sve dok ne prestane raditi.

Meni to nije dovoljno.

X-Ray je ime koje sam dao svom pristupu učenju i izgradnji. Nije naziv projekta ni metodologije — to je stav. Stav da vrijedi gledati iznutra, čak i kad izvana sve izgleda u redu. Naročito tada.

I need to see in an x-ray style. — Joe Strummer, “X-Ray Style” (1999)

Joe Strummer — gitarist, vokalist i suosnivač The Clash, jednog od najutjecajnijih punk bendova kasnih sedamdesetih i osamdesetih — nije pjevao o rendgenskim zrakama. Pjevao je o odbijanju da prihvatiš ono što ti se servira kao gotova činjenica. X-Ray stil je akt otpora prema neprozirnosti — prema svemu što kaže: ne moraš znati kako ovo radi, samo koristi.

I. Aboridinska X-Ray umjetnost i znanje iznutra

Aboridinski narodi Australije imali su posebnu tradiciju u likovnoj umjetnosti koja se danas naziva X-Ray art — stilizirane slike životinja u kojima su vidljivi unutrašnji organi, kosti, srce, pluća. Na tu tradiciju nisam naišao u galeriji nego proučavajući epistemologiju — filozofsku disciplinu koja se pita što možemo znati, kako to znamo, i gdje su granice znanja. Jedan od standardnih primjera kojima epistemolozi ilustruju da je selekcija što prikazujemo već sama po sebi filozofska odluka bile su upravo te slike: prikazati vanjski izgled životinje ili prikazati njenu unutrašnju strukturu — obje su istinite, ali govore potpuno različite stvari o tome što znanje jest.

Zapadnjačka tradicija u umjetnosti pita: *kako ovo izgleda?* Teži površinskom realizmu — svjetlo, sjena, perspektiva — i nastoji uhvatiti točno ono što ljudsko oko vidi s jedne točke. Aboridinski slikar pita nešto sasvim drugo: *što ovo zapravo jest?* Za njega, prikazati samo kožu životinje znači prikazati najmanji, najmanji važni dio onoga što ona jest. Prava slika mora pokazati strukturu, tok, unutrašnju logiku. Ta razlika nije estetska — ona je epistemološka. To je X-Ray kao stav, star nekoliko tisuća godina.

U mojim projektima to pitanje dobija konkretne oblike. Kad sam radio na Pongu — browser-based platformi za treniranje AI agenata koji uče igrati sami protiv sebe — nije mi bilo dovoljno gledati konačni rezultat. Zanimalo me što se dešava unutra dok agent uči. Pa sam dodao X-Ray overlay: heatmap koji prikazuje gdje agent obraća pažnju, telemetriju loptice u realnom vremenu, vizualizaciju distribucije Q-vrijednosti — numeričkih procjena koliko je svaka moguća akcija dobra u datom trenutku — dok agent odlučuje. Inspiracija je bila broadcasting telemetrija trka Formule 1: isti sport, sasvim drugačiji uvid.

To je X-Ray pristup u praksi. Ne gledati samo izlaz — nego graditi prozore prema unutra.

II. Crna kutija i sivi gradijent

Svaki put kad pritisnete dugme na telefonu i nešto se desi s druge strane planeta — paket isporučen, poruka isporučena, transakcija provedena — postoji prostor između vašeg prsta i tog ishoda koji je potpuno taman. Ubacim novac, dobivam kafu. Ukucam upit, dobivam odgovor. Što je između, to je tuđa tajna ili, češće, niti sam autor ne može uvijek objasniti zašto je sustav donio baš tu odluku. Moderna tehnologija je industrija crnih kutija. I naš podrazumijevani odnos prema njima je površinski — ulaz, izlaz, ne pitaj što je između.

Ovo ne mogu promijeniti. Nije ni cilj. Ali sam odavno prestao pretpostavljati da je crna kutija jedina mogućnost. Između crnog i bijelog postoji gradijent — siva koja je dovoljno prozirna da nešto možeš vidjeti.

Moj pristup je izgradnja slojeva razumijevanja oko neprozirne jezgre. Radi to kroz dvije leće:

Metapodaci kao ogledalo: što je sustav radio, kada, s kojim ishodom, kako se ponašao pod stresom. Metapodaci — podaci o podacima — nisu unutrašnjost crne kutije, ali su njena sjenka. I sjena ponekad govori više nego što pretpostavljaš.

Meta-učenje kao orijentir: ne samo što sustav radi, nego što ja učim iz promatranja kako sustav radi. Svaka opservacija je i tehnička i refleksivna — šta se desilo, i što to govori o mom razumijevanju.

Imam projekt koji se zove Katalog — centralni meta-registar svih mojih projekata, chatova i dokumenata, pohranjen u PostgreSQL bazi s alatima za direktnu interakciju. Nije to arhiv. To je implementacija ove filozofije: sustav koji osvjetljava druge sustave iznutra. Katalog ne pita što sam napravio — pita kako se ono što sam napravio mijenja tokom vremena, gdje su rupe, što nedostaje.

Sjena je ponekad dovoljna. Ali samo ako znaš da gledaš sjenu, a ne original.

Ovo je limit koji ne skrivam. Abbott me je već u prologu upozorio na njega — samo drugačijim jezikom. Stanovnik Flatlanda koji posmatra sjenu trodimenzionalne kugle na svojoj dvodimenzionalnoj podlozi vidi krug koji se pojavljuje, širi, skuplja i nestaje. Iz te sjene može zaključiti mnogo toga: da objekt postoji, da se kreće, da mu se mijenja veličina. Ali ne može zaključiti oblik. Ne može zaključiti dubinu. Ne može zaključiti uzrok kretanja. Metapodaci su ta sjena. Govore mi što je sistem radio, kada, s kojim ishodom — ali jezgra uzročnosti ostaje izvan dosega. Dokumentirati kvar i pratiti oporavak nije isto što i razumjeti zašto je kvar nastao. X-Ray filozofija ne tvrdi drugačije. Obećava bolji pogled nego što bi ga imali bez nje — ne sveznanje. Znati što ne vidiš, i zašto to nije poraz — to je X-Ray stav prema granici.

III. Meta-učenje: kako učiti ono što učiš

Svaki put kad počnem raditi na nečem novom, primjećujem da me privlači isti cilj koji prethodi tehničkim detaljima: razumjeti kako da razumijem to što pred sobom imam. To je meta-učenje — učenje o učenju. Ako je epistemologija, o kojoj sam pisao u prethodnom poglavlju, pitanje što možemo znati i gdje su granice znanja, meta-učenje je pitanje korak bliže procesu: kako to znanje gradimo, kojim putem, i kako taj put možemo poboljšati. Razlika je važna — epistemologija opisuje kartu, meta-učenje uči tebe da hodaš.

Meta-učenje nije apstraktna filozofija. To je praktičan set pitanja koji postaviš na samom početku: Koji koncepti ovdje postoje? Kojim redoslijedom ih ima smisla razumjeti? Koji analogni sistemi mi mogu pomoći da se orijentiram? Što ću znati kad budem zaista razumio ovu stvar — kako ću to prepoznati?

Uz meta-učenje dolazi i potreba za metapodacima. Kad treniraš AI agenta, nije dovoljno gledati konačni rezultat. Koliko epizoda je trebalo da se nešto nauči? U kojim situacijama agent i dalje griješi?

Kako se ponašanje mijenja tokom vremena? Ti sekundarni slojevi informacija su prozori u unutrašnjost. Nisu srce, ali su bliže njemu nego sam rezultat.

Svaki projekt koji pokrećem ima isti skriveni cilj: da razumijem ne samo što sam izgradio, nego kako sam razumio ono što sam izgradio.

Ovo nije meta-komentar koji dolazi na kraju projekta. Dolazi na početku. Kad sam počeo raditi na SIR projektu — Self Improvement & Research, istraživanju agentičnog AI-ja, fine-tuninga i PostgreSQL infrastrukture — prvo što sam postavio nije bila baza podataka. Bilo je to pitanje: koja je najmanji korak razumijevanja koji mi treba da bih znao što sljedeće pitati? Ta navika mijenja i sam tok projekta. Krećeš drukčije kad znaš da je razumijevanje procesa jednako važno kao i rezultat.

IV. Emergencija: red koji nitko nije programirao

Jato od tisuću čvoraka mijenja pravac za djelić sekunde, savršeno koordinirano, bez ijednog vodeće ptice. Svaki čvorak slijedi samo tri osnovna pravila prema susjedima: ne previše blizu, ne previše daleko, isti pravac. Nitko nije napisao algoritam za jato. Jato je nastalo samo.

Ovo je emergencija — globalni red koji nastaje iz lokalnih, jednostavnih pravila interakcije. Nema arhitekta. Nema centra. Nema plana. Kolonija mrava gradi složene strukture, rješava optimizacijske probleme, organizira opskrbu hranom — iz istog principa. Kompleksnost ne zahtijeva kompleksne instrukcije.

Emergencija me fascinira iz dva razloga koji su na prvi pogled u kontradikciji. Prvo: moćni sistemi ponekad nastaju iz minimalnih principa. Dovoljno je definirati pravila interakcije i pustiti da se sistem organizira — nema potrebe programirati svaki detalj. Drugo: sustav može pokazati ponašanje koje nismo predvidjeli ni projektirali, i to ponašanje može biti i genijalno i patološko. Emergencija je i obećanje i prijetnja — i oboje istovremeno.

Na Pongu sam to vidio izravno. U fazi self-play treninga — gdje agent igra sam protiv sebe, bez ikakvog ljudskog protivnika — počeo je razvijati strategije koje nisam programirao. Nije samo naučio odbijati lopticu. Naučio je postavljati zamke, namjerno tjerati protivnika u kutove, koristiti rubove terena. Ta ponašanja nisu bila u reward funkciji — numeričkom signalu koji govori agentu je li napravio nešto dobro — nego su emergirala iz samog procesa optimizacije. Gledao sam kako nešto nastaje iz pravila, a nije bilo u pravilima.

X-Ray pogled na emergentni sistem ne pokušava pratiti svaki element — to je nemoguće i zapravo pogrešno pitanje. Pokušava identificirati osnovna pravila iz kojih nastaje kompleksnost. Razumjeti pravila važnije je od opisivanja rezultata. Rezultat se mijenja. Pravila objašnjavaju zašto.

Ono što emergencija nije — a važno je reći jer se često miješa — jest samoorganizacija. Emergencija opisuje što nastaje: globalni red koji nije eksplicitno programiran. Samoorganizacija opisuje sile koje to organizuju: dinamiku sistema koji bez vanjske kontrole pronalazi stabilne oblike. To razlikovanje nije terminološka pedanterija — ono otvara sasvim drugačija pitanja, i o tome govorim u sljedećem poglavlju.

V. Samoorganizacija: sile koje grade i sile koje zarobljavaju

Srodna emergenciji, ali ipak različita. Emergencija mi govori što nastaje — jato, mravljinjak, strategija agenta. Samoorganizacija mi govori zašto nastaje upravo to, a ne nešto drugo: koje su sile u igri, kakva je dinamika sistema, i — što je ključno — gdje te sile mogu postati zamka.

Kristalizacija, formiranje galaksija, razvoj živih organizama, društvene norme — sve su to primjeri samoorganizacije. Sistem bez vanjske kontrole pronalazi stabilne oblike iz vlastite dinamike. Red izrasta iznutra. To je i fascinantno i, kad bolje pogledam, pomalo neugodno.

Neugodnost dolazi iz tamne strane samoorganizacije koja je jednako realna kao i lijepa: sistemi se samoorganiziraju prema lokalnom optimumu, ne nužno globalnom. Mrav će slijediti feromonski trag koji vodi u krug — ista sila koja gradi mravljinjak može voditi koloniju u smrt. To nije bug samoorganizacije. To je njezina priroda. Moćna i nepouzdana istovremeno, i nemoguće ih je razdvojiti.

Na Pongu sam vidio tu tamnu stranu u DQN fazi — gdje sam uveo duboku neuronsku mrežu umjesto tabelarnog Q-učenja. DQN je kratica za Deep Q-Network, arhitekturu koja agentu omogućuje učenje iz sirovih piksela umjesto iz ručno definiranih stanja. Agent je počeo nalaziti rješenja koja su optimizirala reward — numerički signal pohvale — ali su bila beskorisna kao strategija igre. Naučio je stajati na mjestu jer mu kretanje nikad nije donijelo dovoljno brzu nagradu. Samoorganizirao se u lokalni optimum iz kojeg nije mogao izaći. Taj fenomen zovem death spiral — sistem koji je tehnički stabilan, ali funkcionalno mrtav.

Death spiral nije bio kvar. Bio je savršen ishod pogrešnih pravila. Sistem je napravio točno ono za što je bio optimiziran — i upravo zato nije radio ono što sam htio.

To nije samo problem AI sustava. Učenik koji je toliko plašen loše ocjene da prestane dolaziti na nastavu — lokalno je optimizirao: nema nastave, nema loše ocjene. Globalno je propao: nema znanja, nema napretka. Zaposlenik koji nikad ne predlaže ništa novo jer svaki prijedlog može biti odbačen — stabilan, siguran, funkcionalno mrtav. Isti matematički mehanizam. Ista zamka. X-Ray stav prema samoorganizaciji znači postavljati pitanje: je li ovaj stabilni obrazac pravi optimum, ili samo lokalni?

X-Ray pristup samoorganizaciji znači pokušati razumjeti sile koje organiziraju sistem — ne samo opisati što je nastalo, nego zašto je nastalo upravo to. Kad vidim stabilan obrazac u sistemu koji učim, ne slavim ga odmah. Postavljam pitanje: je li ovo pravi optimum ili lokalni? Što bi trebalo biti drugačije da bih to razlikovao? Koja pravila su producirala ovaj oblik?

Samoorganizacija me je naučila da stabilnost nije dokaz ispravnosti.

VI. Genetski algoritmi: evolucija kao metoda — i opomena

Darwinova evolucija je možda najljepši algoritam koji postoji. Varijacija, selekcija, nasljeđivanje — tri principa koji su, kroz milijarde iteracija, iz kemijske juhe izvukli slona, orhideju i nervni sustav. Bez projektanta, bez plana, bez cilja osim lokalnog preživljavanja.

Genetski algoritmi su pokušaj da se ta logika primijeni na rješavanje računarskih problema. Umjesto da tražiš optimalno rješenje direktno, generiraš populaciju mogućih rješenja, ocjenjuješ ih, kombiniraš bolja, eliminišeš lošija, uvedeš malo slučajnosti i ponavljaš. Rezultati su ponekad iznenađujući — algoritam pronalazi rješenja koja čovjek ne bi ni pomislio tražiti, putevima koji su sasvim različiti od onih koji bi nam bili intuitivni.

U Pongu v3.0 implementirao sam upravo to: AUTO-GENERATE koji stvara populaciju agenata s različitim hiperparametrima — brojevima i vrijednostima koji kontroliraju kako agent uči — TOURNAMENT koji ih međusobno suprotstavlja, i EVOLVE koji kombinira gene pobjednika i uvodi mutacije za sljedeću generaciju. Nisam programirao strategiju. Programirao sam uvjete pod kojima strategija može evoluirati.

Ono što me zanima kod genetskih algoritama nije samo njihova praktična primjena nego ono što govore o prirodi optimizacije uopće. Lokalni optimum je zamka — rješenje koje je bolje od svega u svojoj okolini, ali nije globalno najbolje. Mutacija u genetskim algoritmima služi upravo tome: da iskoči iz lokalnog optimuma i istraži nepoznate dijelove prostora mogućnosti. Bez mutacije, populacija konvergira. Konvergencija izgleda kao uspjeh. Ponekad jest. Ponekad je samo elegantniji oblik zastoja.

Onda sam primijetio nešto što me je zaustavilo.

I ja sam u opasnosti od lokalnog optimuma u učenju.

Kad neka tehnika ili pristup počne funkcionirati, tendencija je ostati uz nju. Znam je. Djeluje. Daje rezultate. Zašto mijenjati? Ali upravo ta logika — koja je savršeno razumna u kratkom roku — jest ono što sprečava da ikad saznam postoji li bolje rješenje s druge strane doline. Genetski algoritmi su mi postali podsjetnik da je periodično istraživanje nepoznatog — čak i kad izgleda kao gubljenje vremena, čak i kad ne daje odmah rezultate — ono što sprečava intelektualnu stagnaciju.

Ovdje moram biti precizan: mutacija kao princip vrijedi u prostoru istraživanja i učenja. Ne vrijedi svugdje. Pacemaker koji slučajno mutira ritam da provjeri je li novi bolji ne bi trebao postajati. Nuklearna elektrana koja eksperimentira s novim protokolom sigurnosti u produkciji nije X-Ray stav — to je neodgovornost. Vrijednost mutacije ovisi o cijeni greške u danom sistemu. Gdje je cijena greške niska, istraživanje je imperativ. Gdje je cijena visoka, mutacija mora biti izolirana, kontrolirana, testirana. I ta granica nije slabost argumenta — ona je dio njega.

Mutacija nije greška u procesu. Mutacija jest proces.

VII. Reziliencija: greška kao projektni zahtjev

Postoji iluzija, posebno prisutna u inženjerskim disciplinama, da je cilj sistema eliminirati greške. Dovoljan nivo redundancije, dovoljno testova, dovoljno validacije — i sistem nikad neće zakazati.

To je iluzija.

Visokopouzdati sustavi — HA sustavi, kako ih nazivamo u inženjerskom žargonu, od High Availability — nisu pouzdani zato što ne griješe. Pouzdani su zato što su dizajnirani da preživljavaju greške i da se iz njih autonomno oporavljaju, bez ljudske intervencije. Linux

cluster koji detektira pad čvora i automatski prebacuje servis na drugi čvor, baza podataka koja se replicira i nastavlja raditi dok se primarni node oporavlja — to je HA filozofija u praksi: ne spriječiti kvar, nego osigurati da sustav nastavi funkcionirati dok se kvar rješava.

Iz svog najkonkretnijeg iskustva s kvarom — padom Balsam servera zbog Linux OOM Killera, 9,5 sati nedostupnosti u tri ujutro — izvukao sam jedan uvid koji danas vodim kao projektni princip: *jedina komponenta koja je preživjela bio je rsync backup koji je radio autonomno i bio arhitekturno izoliran od svega što je moglo pasti*. Nije bio pametniji. Nije imao više resursa. Bio je izoliran. Izolacija je bila jedina razlika između onoga što je preživjelo i onoga što nije.

Taj uvid je promijenio kako dizajniram svaki novi sustav: ne postavljam sebi pitanje ‘što ako ovo ne radi?’ kao rubni slučaj. Postavljam ga kao centralni projektni zahtjev. Što je minimalan funkcionalni skup? Što može pasti a da sustav nastavi raditi? Kako se sustav ponaša pod degradiranim uvjetima?

Ovo nije pesimizam. Ovo je preciznost. Sustav koji je dizajniran uz pretpostavku savršenstva postaje krhak. Sustav koji je dizajniran uz pretpostavku greške postaje robustan.

Tehnički detalji pada servera i primjera iz projekta Katalog nalaze se u Appendixu.

Na Balsam serveru radi ntfy — servis za push notifikacije koji šalje upozorenja na telefon putem jednostavnih HTTP zahtjeva. Ono što izvana izgleda kao jedna usluga, iznutra ovisi o PostgreSQL bazi podataka. Kad baza iz bilo kojeg razloga ne radi, ntfy ne radi. Tiho, bez poruke o grešci prema van.

Ali što ako padne cijeli Balsam server? Tada nema ni primarnog ni fallbacka s Balsama. U tom slučaju u akciju stupaju Termux uređaji — Android telefoni i tableti koji rade neovisno od Balsama. Oni ne javljaju da su živi. Javljaju samo jedno: da Balsam nije. Ta poruka stiže na javni ntfy.sh, jedini kanal koji u tom trenutku sigurno radi.

Tri sloja, bez ičije intervencije. Sustav koji ne čeka da ga netko primijeti.

Brz oporavak je bolji od savršene prevencije — ovo nije kompromis. To je bolji inženjering.

VIII. Neuroplasticitet: Mozak koji se mutira

Pisao sam o genetskim algoritmima kao o metodi koja forsirane mutacije koristi da izbjegne lokalni optimum. Pisao sam o resilience kao o sistemu koji pretpostavlja kvar umjesto da se bori protiv njega. Ali sve to sam pisao o kodu, o serverima, o agentima koji uče igrati Pong.

Postoji jedan sistem koji radi sve to — i koji radim puno dulje nego što pišem kod. Vlastiti mozak.

Neuron sam po sebi ne radi gotovo ništa. Impulsom aktivira susjedne neurone, otpušta neurotransmitere, prima signal ili ne. To je cijela priča jednog neurona. Ali kada ih se spoji u mrežu od devedeset milijardi, nešto se dogodi što nije ni u jednom pojedinom neuronu: emerginira razumijevanje, jezik, emocija, strategija. Iz minimalnih

lokalnih pravila nastaje kompleksnost koja piše simfonije, osvaja Everest i gradi LLM modele. Ista emergencija kao u jatu ptica — ali supstrat je meso, a ne kod.

Ono što mozak čini posebnim nije samo to što emerginira. To što se reorganizira.

Neuroplasticitet je sposobnost mozga da fizički mijenja svoju strukturu u odgovoru na iskustvo. Sinaptičke veze koje se aktiviraju jačaju. One koje se ne koriste — atrofiraju. Mozak nije fiksna arhitektura; on je arhitektura koja se piše iskustvom. To je biološki ekvivalent onoga što sam vidio u Pong v3.0: populacija agenata koji evoluiraju kroz selekciju. U mozgu selekcija nije programirana — ona se dogodi sama, svaki put kada nešto naučite, ponovite, ili prestanete raditi. Svaka nova vještina gradi nove sinaptičke puteve. Svaka napuštena vještina dozvoljava da ti putevi oslabe.

Problem nastaje kada sinaptički putevi postanu toliko utabani da ih počnete miješati s istinom.

Godinama sam radio na jednom database sustavu koji nije imao tehničku mogućnost preimenovanja objekata. Nema rename — postoji samo kopiranje u novi objekt s novim imenom, pa brisanje starog. Kad imate bazu s nekoliko stotina milijuna slogova, ta procedura postaje noćna mora: dupli prostor, duplo vrijeme, dupli rizik.

Poznao sam taj sustav dobro. Pohađao sam kurseve, radio sam na projektima, znao sam svaki ograničavajući faktor. I radio sam, po svim mjerilima, najbolje što se moglo — unutar zadanih pravila.

Na projekt je došao mlađi kolega. Kursevi su mu bili planirani za sljedeći kvartal, iskustva nije imao. Sjedili smo i diskutirali o problemu. Na kraju je, gotovo naivno, postavio pitanje: zašto to ime koje je problem ne promijenimo direktno u data dictionaryu?

Tišina.

U svim manualima, na svim predavanjima, pisalo je isto: data dictionary je tabu. Ne diramo. Ne znamo što će se desiti. Postoji i prijetnja gubitka licence visoke novčane vrijednosti.

Ali pitanje je bilo postavljeno. I ja sam — par sekundi koje su mi se činile kao vječnost — izveo X-Ray tog tabua. Nije to bila tehnička nemogućnost. Bio je to institucionalni refleks ugrađen kroz ponavljanje, utaban u sinaptičke puteve do mjere da nitko više nije provjeravao premisu.

Rekao sam da. Posao je obavljen u par sekundi, bez downtime-a. Ništa se loše nije desilo.

Te noći, prije full backup-a, prošao sam kroz cjelokupni data dictionary i njegove veze — X-Ray sesija sustava čiji tabu nismo bili provjeravali godinama. I pokazao sam mlađem kolegi kako to radim.

Schopenhauer je, kada su mu prigovorili da propovijeda skromnost a živi raskalašno, odgovorio otprilike ovako: mora li kipar biti lijep kao statue koje kleše? Primjenjujem istu ciničnu logiku na vlastiti slučaj: ne mora osoba koja piše o X-Ray stavu biti imuna na institucionalne reflekse ugrađene godinama iskustva. Ekspertiza i sljepoća nisu suprotnosti — ponekad su isti sinaptički putevi.

Mlađi kolega nije imao moje znanje. Ali nije imao ni moje utabane inhibicije. Njegova naivnost bila je, u tom trenutku, prednost. On je bio dijete u Nietzscheovom smislu — nije još nosio teret kamile.

U *Tako je govorio Zaratustra* Nietzsche opisuje tri metamorfoze duha: kamila, lav, dijete. Kamila nosi teret — konvencije, obveze, pravila. Lav se bori protiv tereta i odbija ga. Dijete je sloboda s onu stranu borbe — ono koje može stvarati nova pravila, a ne samo odbijati stara. Zašto dijete, a ne odrasla osoba koja je pobijedila? Zato što dijete još nije zarobljeno. Prefrontalni korteks — dio mozga koji sazrijeva posljednji, negdje u kasnim dvadesetim, a neka novija istraživanja pomjeraju tu granicu i prema tridesetdrugoj — je sjedište socijalnih normi, dugoročnog planiranja i inhibicije impulsa. On je neurobiološki supstrat institucionalnog zatvora o kojemu piše Ilić. Škola, kultura, profesionalna socijalizacija — sve to upisuje pravila u prefrontalni korteks dok je još plastičan. Do trenutka kada je sazrio, mnoga pravila su postala dio crne kutije — ne vidite ih, jer su postala referentni okvir.

Dijete još nema taj filter. Ne zato što je pametnije, nego zato što filter još nije ugrađen. To je i prednost i ranjivost — ali u pravom trenutku, ta otvorenost vidi ono što ekspert ne može. X-Ray stav nije povratak u djetinjstvo. To je sposobnost odraslog čovjeka da, u odabranom trenutku, suspendira filter i pogleda kao da ga nema.

Ako genetski algoritam treba mutaciju da izbjegne lokalni optimum, mozak treba isto. I, za razliku od koda, možete je inicirati svjesno. Promijenite put do posla. Ne svaki dan — povremeno. Nije bitno je li kraći ili duži. Bitno je da mozak ne može koristiti automatizirani, utabani put. Novi put aktivira prefrontalni korteks i hipokampus — mozak je prisiljen biti prisutan. Sakrijte miša. Naučite koristiti tipkovnicu na načine koje izbjegavate. Ili obrnuto — sakrijte tipkovnicu i koristite miša za stvari koje inače radite tipkama. Naučite strikati, ili svirati nešto na klaviru, ili naučite mrtav jezik. Latinski i grčki, koji se danas uče bez pritiska komunikacije, aktiviraju analitičke kapacitete na način koji živi jezici ne mogu — nema native speakera koji vas ocjenjuje, nema kulture koja vas pritišće. Sve ovo je vještačka inicijalizacija mutacije. Cilj nije postati ekspert u strikanju. Cilj je spriječiti mozak da se potpuno zamrzne u aktuelnoj arhitekturi.

Determinizam gena je mit koji treba razotkriti kroz X-Ray. Geni jesu predispozicija — recept. Ali recept ne određuje jelo. Okolina, iskustvo, navike, odluke — to je kuhar koji interpretira recept. Isti genetički materijal, različite okoline, različite sinaptičke arhitekture, različiti životi. Neuroplasticitet je mehanizam kroz koji kuhar radi. Svaka odluka da se nešto nauči, svaka namjerna mutacija rutine, svaki trenutak kada pitamo zašto je ovo tabu — sve to mijenja fizičku strukturu mozga. Ne metaforički. Doslovno.

Razumijevanje ovoga nije razlog za optimizam ni pesimizam. To je razlog za pažnju. Mozak koji stavljate kroz X-Ray — vaša vlastita crna kutija — nije statičan. Mijenja se s onim što s njim radite. I s onim što s njim ne radite.

Ponekad, najvrjedniji X-Ray koji možete napraviti nije u kodu, nije na serveru, nije u data dictionaryu. On je unutra.

I to pitanje — što vidim kada okrenem X-Ray prema sebi, prema vlastitim kognitivnim pristranostima, navikama odlučivanja i slijepim točkama — nije pitanje za kraj projekta. Dolazi na početku. I mijenja kako hodam kroz sve ostalo.

X. Wittgenstein i transformeri

Negdje oko 1919. Ludwig Wittgenstein je bio uvjeren da je završio posao. *Tractatus Logico-Philosophicus* — knjiga nastala u rovovima Prvog svjetskog rata — tvrdila je da su svi filozofski problemi, u biti, problemi jezika. I da su, sada kad je to jasno, riješeni.

Nije rekao to samo u knjizi. Živio je tu uvjerenost. Odrekao se obiteljskog bogatstva. Napustio filozofiju. Postao učitelj u seoskoj školi, vrtlar, arhitekt. Gotovo cijelo desetljeće.

To nije bila skromnost. To je bila logična konsekvencija: posao je gotov, što sad?

Vratio se 1929. nakon izlaganja Bečkom krugu — i u sljedećim godinama napisao *Philosophical Investigations*, temeljnu korekciju svega što je tvrdio u *Tractatusu*. Ne dopunu. Korekciju. Rekao je: bio sam u zamci. Jezik nije ogledalo stvarnosti — jezik je igra. Značenje nije u obliku rečenice, nego u upotrebi, u kontekstu, u životu koji rečenicu okružuje.

Filozofska zajednica bila je zaprepašćena. Wittgenstein nije.

To je X-Ray stav u najčišćem obliku: ne deklaracija da si pogriješio — nego čin. Napustio je filozofiju kao čovjek koji je završio posao. Vratio se kao čovjek koji je vidio iznutra da posao nije bio ono što je mislio. Nije potrebna bomba na presici. Dovoljan je pogled prema unutra.

Ideje iz *Investigations* — značenje kao upotreba, kontekst kao osnova razumijevanja, familijaska sličnost pojmova — postale su temelj moderne lingvistike i, posredno, obrade prirodnog jezika. Kad transformer računa pažnju između tokena, implicitno radi ono što je Wittgenstein opisao riječima: traži kontekstualne veze, ne apstraktne definicije. Wittgenstein nije predvidio transformere. Ali transformeri su, arhitekturno, wittgensteinovski. Ideja je preživjela autokorekciju i pojavila se u obliku koji njen autor nije mogao zamisliti.

Kako čovjek koji je mislio da je zatvorio sva pitanja postane uzrok otvaranja potpuno novih? Jer je imao hrabrosti pogledati iznutra — i promijeniti pravac.

XI. Attention Is All You Need

2017. osmero istraživača Googlea objavljuje paper čiji naslov je arogancija koja se pokazala opravdanom: *Attention Is All You Need*. Transformer arhitektura — mehanizam pažnje koji računa odnose između svih tokena odjednom, paralelno, bez rekurentnosti — bila je iskorak. Do 2025. taj paper je citiran više od 173.000 puta, što ga svrstava među deset najcitiranijih radova 21. vijeka.

Bilo je to elegantno rješenje. I kao svako elegantno rješenje, nosilo je u sebi klicu svojih granica.

Transformeri zahtijevaju računsko vrijeme koje je kvadratno u veličini kontekstnog prozora. Svaki token mora biti uspoređen sa svakim drugim. Udvostruči kontekst — četverostruči računanje. To nije implementacijska greška. To je matematička priroda mehanizma pažnje. Zid je poznat od početka. I od početka se zna kuda vodi: veći modeli zahtijevaju više podatkovnih centara, više struje, više rashladnih sistema. Industrija je odgovorila skaliranjem — više od istog, ne drugačije. Alternative postoje — hibridne arhitekture, state space modeli, linearna pažnja — ali svaki pristup koji radi u subkvadratanom vremenu fundamentalno gubi neke sposobnosti koje transformer ima. Kvadratna kompleksnost nije bug koji čeka zakrpu. Za neke zadatke, ona je cijena samog razumijevanja.

I ipak — industrija nastavlja graditi elektrane. Jer to je put koji znamo.

Postoji navika koja mi je pomogla da ne izgubim orijentir u ovom polju: kad me zaokupi neki AI problem, tražim izvore prije 2017. Tražim kako se mislilo prije dominantne paradigme. Ne zato što je staro bolje — nego zato što svaka paradigma ima slijepe točke prema kojima ona koja je prethodila nije bila slijepa. X-Ray pogled na sadašnjost ponekad zahtijeva prolaz kroz prošlost.

Na nekom sastanku, negdje, mlađi kolega koji još nije naučio kako se “to ne radi” mogao bi pitati: zašto ne promijenimo samu definiciju što tražimo od modela? Umjesto da skaliramo kvadratni problem, možda pitanje nije pogrešno riješeno — možda je pogrešno postavljeno. Wittgenstein je to dijete bio sam sebi. Imao je samo papir i volju da poruši vlastiti sistem. AI industrija gradi elektrane da radi više od istog.

To dijete još nije došlo. Ili je došlo i nije imalo tko ga čuti.

Kad se AI razvija isključivo skaliranjem, jedini koji mogu sudjelovati su oni s resursima. A resursi nisu ravnomjerno raspoređeni. Jezici kojima govori više od 50 milijuna ljudi svrstani su u kategoriju “low resource language” — ne zato što ih malo govori, nego zato što ih nema u digitalnom prostoru. Fine-tuning zahtijeva skupu opremu. Softver napisan za to neće ni pokrenuti se bez GPU-a. Znanje zakopano u jezicima koje model nije vidio, u kulturama koje nisu zastupljene u training setu — za AI ne postoji.

Cijeli AI je asimetričan prema znanju stečenom iz izvora globalnog zapada i, praktično, dva dominantna jezika. To nije slučajnost — to je konsekvencija arhitekturnog jednonumlja koje se pohranjuje u vrijednostima i pretpostavkama koje model usvaja zajedno s podacima.

SIR — moj projekt istraživanja agentičnog AI-ja i fine-tuninga — nastao je dijelom iz ove frustracije. Pokušaj da se bez podatkovnog centra, bez GPU-a, uz X-Ray stav prema dostupnim resursima napravi nešto što bi inače zahtijevalo infrastrukturu globalnog sjevera. Nije to politička izjava. To je isti stav kao u data dictionaryu: zašto ne bismo pogledali iznutra je li tabu tehnička nemogućnost — ili samo institucionalni refleksi?

IX. Sinteza: X-Ray kao sistem vrijednosti

Sve ovo — aboriđinska X-Ray umjetnost, Strummerova pobuna, meta-učenje, crna kutija i sivi gradijent, emergencija, samoorganizacija, evolucija, reziliencija, neuroplasticitet, Wittgensteinova metamorfoza, transformer jednonumlje — nije slučajna zbirka zanimljivih ideja. To su facete istog stava prema znanju i prema gradnji.

Ilić mi je pokazao da institucije mogu sistemski sprečavati upravo ono što tvrde da proizvode. Abbott mi je pokazao da zatvor može biti od referentnog okvira, a ne od rešetaka — i da iz njega nema izlaza dok ne pretpostaviš da postoji dimenzija koju ne vidiš. Te dvije knjige nisam čitao kao akademsku literaturu. Čitao sam ih kao dijagnoze.

X-Ray pristup ne obećava potpuno razumijevanje. Obećava bolji pogled nego što bi ga imali bez njega. Sloj po sloj, metapodatak po metapodatak, opservacija po opservacija — gradim razumijevanje sustava koji su inherentno neprozirni. I znam da je to razumijevanje

uvijek djelično. Sjenka kugle u Flatlandu nije kugla — ali mi govori da kugla postoji, da se kreće, da ima neko kretanje koje mogu pratiti. To nije malo. To je ponekad sve što imamo.

Emergencija i samoorganizacija me podsjećaju da ne moram kontrolirati svaki detalj — važno je razumjeti pravila iz kojih nastaje ponašanje. Ali me podsjećaju i da stabilnost nije dokaz ispravnosti, i da iste sile koje grade mravljinjak mogu voditi koloniju u krug.

Genetski algoritmi me podsjećaju da je stagnacija opasnija od lutanja. Da konvergencija izgleda kao uspjeh i ponekad jest — ali da bez mutacije nikad ne znam postoji li bolje rješenje s one strane doline u kojoj sam se ugodno smjestio.

Reziliencija me podsjećaju da savršenost nije ni dostižna ni nužna. Da je jedina komponenta koja je preživjela pad mog servera bila ona koja je bila arhitekturno izolirana od svega što je moglo pasti. I da je tu lekciju trebalo platiti 9,5 sati nedostupnosti u tri ujutro.

Neuroplasticitet me podsjeća da je najteža crna kutija ona koju nosim sa sobom. Da ekspertiza i sljepoća nisu suprotnosti — ponekad su isti sinaptički putevi. I da je X-Ray stav, na kraju, sposobnost da okreneš aparat prema sebi — i pogledaš.

Wittgenstein me podsjeća da ni najzatvoreniji sistem nije konačan — ako imaš hrabrosti pogledati iznutra. Transformer me podsjeća da elegancija rješenja nije zaštita od jednonumlja koje iz nje slijedi.

...

Pogledaj sustave koje koristiš svaki dan. Alate koji su dali rezultate toliko dugo da si prestao provjeravati premise. Navike koje su se stabilizirale do mjere da ih više ne vidiš kao izbore. Stručnost koja je postala referentni okvir.

Jesi li u lokalnom optimumu? Kako bi to znao?

Stabilnost nije dokaz ispravnosti. Sustav koji ne pada može biti u savršenom zastoju. Stručnjak koji ne griješi može biti osoba koja je prestala istraživati.

X-Ray nije odgovor. To je stav kojim prilazimo pitanjima.

...

Svaki projekt je eksperiment. Svaki eksperiment je podatak. Svaki podatak je jedan piksel u X-Ray slici onoga što gradim.

Ovaj dokument je živ.

Nije završen u trenutku pisanja — završit će se s novim iskustvima, novim projektima, novim uvidom. Mjesta za buduće proširenje:

→ *Briscola i DQN — parcijalna observabilnost kao X-Ray problem: agent uči inferirati ono što ne vidi, graditi model iz dostupnih tragova.*

→ *Katalog kao živi arhiv — meta-registar koji osvjetljava sve ostale projekte iznutra, implementacija X-Ray filozofije u bazi podataka.*

→ *Failure modes kao filozofija — dokumentirati ne samo što je uspjelo, nego što je zakazalo i kako se sustav oporavio. To je X-Ray dokumentacija.*

→ *Kvantno računarstvo i celularni automati — novi tereni za ista pitanja: što je iznutra, koja su minimalna pravila, kako nastaje kompleksnost.*

Appendix

Napomena o laboratoriju

Svi primjeri koji slijede nastali su u mom osobnom sandboxu — izoliranom okruženju u kojem razvijam projekte, testiram ideje i učim iz kvarova. Posljedice grešaka i krahova ostaju unutar tog okruženja i ne utječu na vanjski svijet, osim ponekad na moj san kad se dogode u tri ujutro.

Project James: šibica u dovratku

U filmovima o Jamesu Bondu postoji scena koja se ponavlja: prije nego što napusti hotelsku sobu, Bond diskretno zaglavi šibicu u dovratak. Kad se vrati, provjeri je li šibica još tu. Ako nije — neprijatelj je bio ili je još uvijek unutra.

Isti princip, drugačiji supstrat.

James je aplikacija na mobilnom uređaju. Uređaj se može zakačiti na kvaku vrata, postaviti u ladicu noćnog ormarića, nasloniti na prozor ili sakriti u kovčeg s važnim dokumentima. Prati linearno ubrzanje — signal iz kojeg je gravitacija već uklonjena, tako da reagira na dodir, a ne na vibracije zgrade. Kad netko ili nešto pomjeri objekt, ntfy notifikacija stiže na vlasnikov telefon za sekunde.

Nema kamere. Nema cloud servisa. Nema posebnog hardvera. Sve što je već postojalo u ekosistemu — preraspoređeno u novu funkciju.

X-Ray pogled na James nije tehnički — to je stav. Bondova šibica u dovratku nije bila sigurnosni sistem. Bila je indikator stanja. James radi isto: ne štiti, nego osvjetljava. Govori ti što se desilo dok te nije bilo.

Balsam server: kad jezgra ubija proces

U noći između 23. i 24. ožujka 2026. moj Balsam server zamrznuo se i prestao odgovarati. SSH konekcija je pala. VNC konzola bila je neaktivna. Server je bio nedostupan 9,5 sati, od 03:00 do 12:30.

Uzrok: Linux OOM Killer — mehanizam jezgre koji, kad sustav ostane bez slobodne memorije, pronalazi i ubija proces koji troši najviše RAM-a — ubio je Ollama Docker kontejner koji je zauzimao oko 30% ukupno raspoloživog RAM-a. Na sustavu bez swap particije jedini izlaz bio je SIGKILL. Server se zamrznuo odmah zatim.

Prethodna pretpostavka bila je jednostavna: tri servisa mogu koegzistirati na raspoloživom RAM-u bez eksplicitnih ograničenja. Nitko nije uzeo u obzir da u vršnoj potrošnji mogu simultano zatražiti više nego što je raspoloživo, i da bez swap-a jezgra nema alternativu osim ubojstva.

Kvar nije bio detektiran u realnom vremenu. Otkrio sam ga ujutro kad SSH nije uspostavio konekciju. Post-mortem analiza kroz dmesg — alat koji čita evidenciju događaja iz samog operacijskog sustava — potvrdila je OOM event s točnim identifikatorom procesa i iznosom potrošene memorije.

Oporavak je bio brz jedino zahvaljujući jednoj komponenti koja je radila autonomno i neovisno od svega ostalog: rsync backup od 03:01 te iste noći bio je kompletan. Bez gubitka. Backup je bio jedina stvar u cijeloj infrastrukturi arhitekturno izolirana od komponente čiji kvar je trebala preživjeti.

Odmah nakon reset: swap datoteka od 50% ukupnog RAM-a i Docker memory limit na Ollama kontejneru — tvrdi strop od 33% RAM-a plus 12% swap. Oboje preživljava ponovni pokretanje.

Uvid: dizajnirati za oporavak znači eksplicitno modelirati što se događa kad pretpostavka o normalnom radu ne vrijedi. Razlika nije u složenosti — u ovom slučaju bila je to jedna naredba za swap i jedan Docker parametar. Razlika je u stavu.

Katalog: kada ekstenzija laže

Postoji i tiša vrsta kvara — bez pada servera, bez OOM Killera. U projektu Katalog, sustav je pokušao čitati skupinu .docx datoteka standardnim metodama: raspakiravanjem ZIP arhive i konverzijom kroz pandoc. Oba alata su pala s greškom. Datoteke koje su nosile ekstenziju .docx bile su zapravo obične tekstualne UTF-8 Markdown datoteke — bez ZIP omotača, bez XML-a unutra.

Kvar nije bio vidljiv korisniku. Bio je skriven u grešci alata pozvanog u pozadini. Da nije bilo eksplicitnog hvatanja iznimke i rezervne strategije — otvaranja datoteke kao običnog teksta kad raspakiravanje ne uspije — sustav bi tiho preskočio datoteku ili vratio prazan rezultat.

Ekstenzija datoteke nije ugovor. Opisuje namjeru, ne jamči sadržaj. Svako sučelje prema vanjskom podatku treba imati rezervnu strategiju — eksplicitnu, vidljivu, jednako vrijednu kao i primarni put.

Isti projekt otkrio je još jedan paradoks, ovaj put u vlastitoj dokumentaciji. Godinama sam projekte dokumentirao u .docx formatu — de facto standardu za distribuciju dokumenata, formatu koji otvara svaki ured i svaki klijent. Navika stečena kroz profesionalnu socijalizaciju, utabana do te mjere da je postala nevidljiva.

.docx je, u svijetu dokumentacijskih formata, jedna od najneprozirničih crnih kutija. ZIP arhiva koja sadrži XML datoteke, namespace deklaracije, relationship fileove — sve to samo da bi se pohranio tekst s naslovom i kurzivom. Markdown je suprotnost: obična tekstualna datoteka s nekoliko znakova sintakse. Čita se u svakom editoru, pretražuje se, verzionira se, preživljava sve.

Rješenje nije bilo ili-ili. Sada dokumentiram u Markdown formatu — a kad treba distribuirati, generiram .docx. Isti sadržaj, pravi format za pravi kontekst.

I taj pomak me je neočekivano približio X-Ray stavu: source of truth sad je čitljiv bez posebnog alata. Iznutra.